

(1)  $y = Ax + n$ ,  $x$  为未知参数,  $(A, y)$  为已知数据,  $n \in N(0, Q)$ , 求  $x$  的极大似然估计

解: ①  $p(y|Ax) \sim N(Ax, Q)$

$$\ln p(y|Ax) = \eta + (y - Ax)^T Q^{-1} (y - Ax) \left(-\frac{1}{2}\right)$$

↑  
与  $x$  无关的项

要使  $\ln p(y|Ax)$  最大, 需使  $(y - Ax)^T Q^{-1} (y - Ax)$  最小, 这便引出最小二乘法。

$$\textcircled{2} L = (y - Ax)^T Q^{-1} (y - Ax), \text{ 记 } e = y - Ax$$

$$\frac{\partial L}{\partial x} = \frac{\partial e^T Q^{-1} e}{\partial x} = \frac{\partial e^T Q^{-1} e}{\partial e} \frac{\partial e}{\partial x} = 2 e^T Q^{-1} \cdot (-A)$$

1xq   qxq   qxn

$$\textcircled{3} \text{ 由必要条件 } \frac{\partial L}{\partial x} (x^*) = 0 \Rightarrow$$

$$2(y - Ax)^T Q^{-1} (-A) = 0$$

$$A^T (Q^{-1})^T (y - Ax) = 0$$

$$A^T (Q^{-1})^T y = A^T (Q^{-1})^T A x^*$$

$$x^* = (A^T (Q^{-1})^T A)^{-1} A^T (Q^{-1})^T y$$

$$\text{若 } A \text{ 可逆, 进一步化简 } x^* = A^{-1} Q^T (A^T)^{-1} A^T (Q^{-1})^T y$$

$$= A^{-1} y \quad (\text{与 } Q \text{ 无关})$$

(2)  $A$  与  $x$  均为未知参数, 求  $A$  与  $x$  的极大似然估计。

① 记  $f(A)$  为  $A$  reshape  $(-1, 1)$ , 即 flatten 后的向量。  
设  $f(A) \sim N(\mu_A, \Sigma_A)$     $x \sim N(\mu_x, \Sigma_x)$

$$\begin{aligned} \textcircled{1} \ln p(A, x | y) &= \ln p(y|Ax) + \ln p(A, x) + \eta \\ &= \ln p(y|Ax) + \ln p(A) + \ln p(x) + \eta \\ &= \left(-\frac{1}{2}\right) (y - Ax)^T Q^{-1} (y - Ax) + \left(-\frac{1}{2}\right) (f(A) - \mu_A)^T \Sigma_A^{-1} (f(A) - \mu_A) + \left(-\frac{1}{2}\right) (x - \mu_x)^T \Sigma_x^{-1} (x - \mu_x) \end{aligned}$$

使得  $\ln p(A, x | y)$  最大, 需使 损失函数  $L$  最小,

$$L = (y - Ax)^T Q^{-1} (y - Ax) + (f(A) - \mu_A)^T \Sigma_A^{-1} (f(A) - \mu_A) + (x - \mu_x)^T \Sigma_x^{-1} (x - \mu_x)$$

$$\textcircled{2} \frac{\partial L}{\partial A} (A^* | \text{已知 } x) = 0 \quad \frac{\partial L}{\partial x} (x^* | \text{已知 } A) = 0$$

$$(1) \frac{\partial L}{\partial x} = 2(y - Ax)^T Q^{-1} (-A) + 2(x - \mu_x)^T \Sigma_x^{-1}$$

$$\Rightarrow x^* = (\Sigma_x^{-1} + A^T Q^{-1} A)^{-1} A^T Q^{-1} y$$

(2) 由于  $y^T = x^T A^T + n^T$ , 因此有 (对称性)

$$\Rightarrow A^* = (y R^{-1} x^T) (\Sigma_A^{-1} + x R^{-1} x^T)^{-1}$$

$$\textcircled{3} A_0 \rightarrow x_1 \rightarrow A_1 \rightarrow \dots \rightarrow x_n \rightarrow A_n$$

↓  
至  $x_n, A_n$  满足一定条件后终止迭代

(3) ① Linear Regression  $y = Ax + n$   
如(1)所示。

② Linear Classification (Binary)

1° Linear Discriminant Analysis

project  $A \rightarrow A'$   
↑  
数据量  $q \times m$     $q \times 1$  ← 二分类

such that 二分类数据之间的方差最大。

随后在直线上找边界进行二分类。

$$A' = A w \quad w \in (m_1 - m_2)$$

其中  $m_i$  为属于  $i$  类的数据的平均值。  
 $m \times 1$

$S_1, S_2$  为类内协方差。

$$\text{损失 } J(w) = \frac{(m_2 - m_1)^2}{S_1^2 + S_2^2} = \frac{w^T S_B w}{w^T S_W w}$$

$$\text{得 } w \propto S_W^{-1} (m_2 - m_1)$$

2° Logistic Regression

$$\text{对 } [\ln y - \ln(1 - y)] = Ax + n$$

进行回归

↑  
logits

但不忍心与把  $y$  处理为 logits 再回归

这样会出现  $\ln 0$ , 做不了。

只能将输入力变为 sigmoid

$$y = \sigma(Ax + n)$$